

TP 2 : Géométrie Algorithmique & Morphologie mathématique



Computer Vision

Ambroise LAROYE-LANGOUËT

Télécom Paris

28 novembre 2025

Table des matières

1	Context et objectifs	2
1.1	Données	2
2	Méthodologies	3
2.1	Pipeline 1	3
2.2	Pipeline 2	3
2.3	Pipeline 3	4
2.4	Pipeline 4	5
3	Pour aller plus loin	5
3.1	Pipeline	5
3.2	Méthodologie et Résultats	6
4	Résultats	8
4.1	Evaluation	8

1 Context et objectifs

L'ophtalmoscopie à balayage laser (SLO) est une modalité d'imagerie de la rétine permettant de réaliser un fond d'oeil à haute résolution et sur un large champ. Elle offre ainsi la possibilité d'observer, sur une seule image, la majeure partie de la surface rétinienne avec une résolution comprise entre 10 et 100 µm. Outre les maladies propres à la rétine, l'observation du fond d'oeil permet de diagnostiquer plusieurs pathologies générales en étudiant la circulation artérielle et veineuse rétinienne. C'est notamment le cas de l'hypertension artérielle et de l'insuffisance rénale. Le diagnostic repose généralement sur une analyse quantitative de l'ensemble du réseau vasculaire présent dans l'image de la rétine, ce qui nécessite une segmentation précise de ce réseau.

L'objectif de ce projet est de proposer une ou plusieurs méthodes automatique de segmentation du réseau vasculaire dans des images de rétine SLO.

1.1 Données

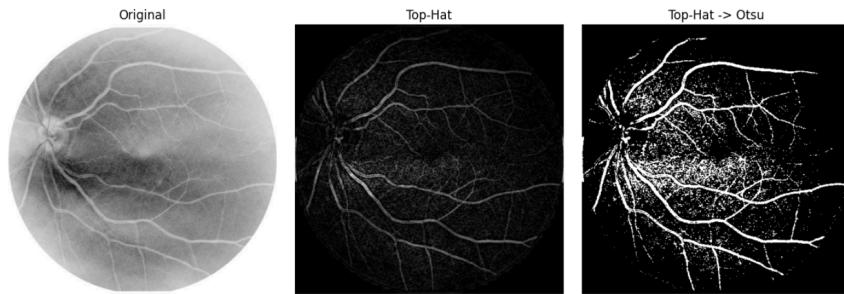
Nous disposons d'un jeu d'images de rétine où l'on identifie les vaisseaux sur le fond de l'oeil. Ils sont plus foncé que le reste de l'image. Nous disposons également de données "ground truth" qui ont été annoté à la main par un expert.

2 Méthodologies

2.1 Pipeline 1

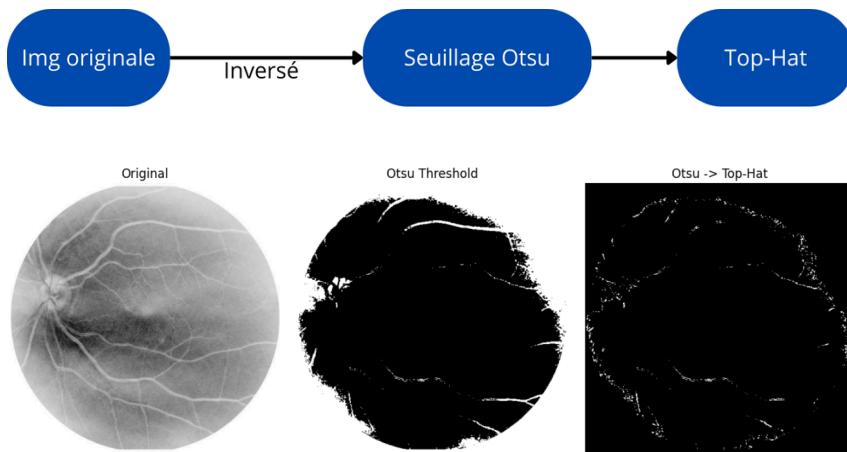


Nous faisons un inversion préliminaire de l'image. Sans cette inversion, les vaisseaux apparaissent sombres sur un fond clair. Nous les inversons donc pour correspondre aux images ground truth. Après cette mise au point, on applique un filtrage morphologique Top-Hat, pour faire ressortir des structures fines et localement plus sombres ou plus claires que leur voisinage. Cette opération est ensuite suivie d'un seuillage d'Otsu.



Remarque :

Si l'on applique le seuillage d'Otsu avant l'opération de Top-Hat, la segmentation devient moins pertinente : le contraste local n'a pas encore été amélioré, ce qui conduit à une carte binaire pauvre en détails. Les figures fournies illustrent clairement cette dégradation.



2.2 Pipeline 2

Précédemment nous pouvons constater sur les images obtenues qu'il y a du bruit résiduel. Dans ce pipeline 2 stratégies classiques de nettoyage peuvent alors être envisagées.

Opening



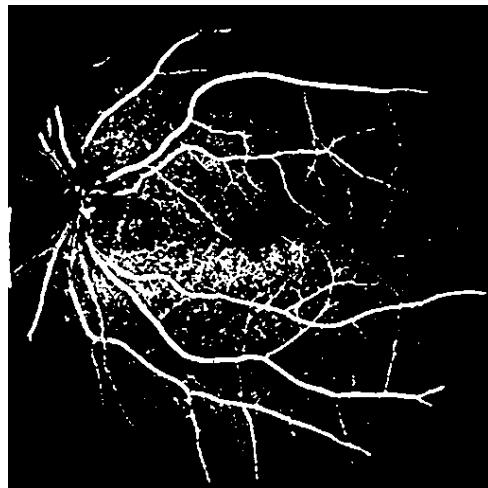
L'ouverture (érosion suivie d'une dilation) permet de supprimer le bruit isolées, au prix d'un amincissement des structures très fines.



Filtre Médian



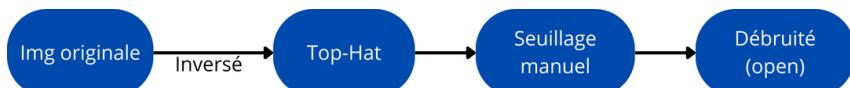
Le filtre médian agit différemment : il réduit le bruit impulsionnel tout en conservant mieux les contours.

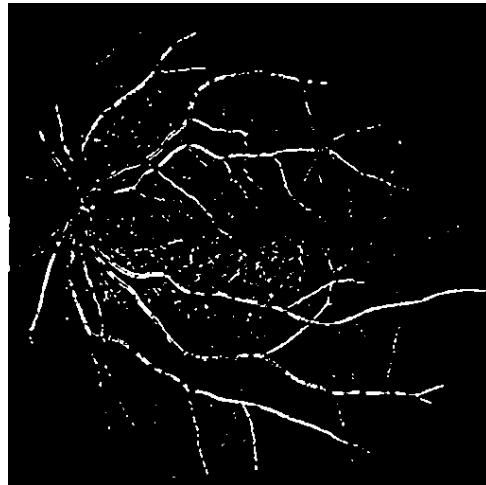


En pratique nous ne voyons pas de différence significative avec l'ouverture morphologique. Il y a une meilleur préservation des terminaisons des "branches", mais plus de bruit dans l'image. Il faut donc choisir le bon compromis entre préservation des formes, "lissage" du bruit.

2.3 Pipeline 3

Le seuillage automatique d'Otsu s'est révélé trop sélectif, entraînant une perte de structures vasculaires fines. Nous avons choisi de tester avec un seuillage manuel.



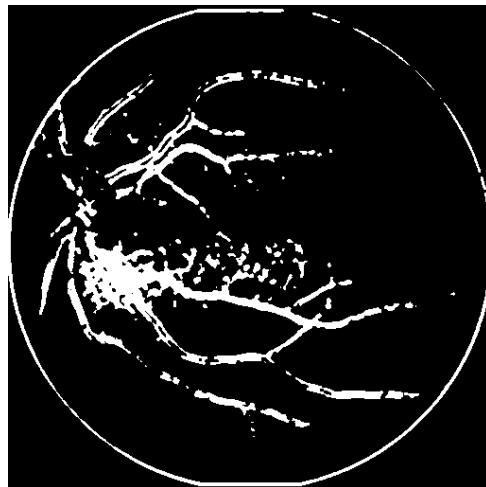


2.4 Pipeline 4



Dans cette méthode nous utilisons le gradient, qui met en évidence les transitions d'intensité. Permettant d'isoler efficacement les contours des vaisseaux. Le gradient morphologique mis en oeuvre est :

$$\text{Gradient} = \text{Dilatation} - \text{Erosion}$$



Remarque : Le gradient extrait également le contour circulaire de l'image de la rétine elle-même. Lors de l'évaluation finale, ce contour global risque d'introduire des faux positifs. Il sera donc nécessaire de restreindre la zone d'intérêt pour ne conserver que la région utile.

3 Pour aller plus loin

3.1 Pipeline



3.2 Méthodologie et Résultats

Dans cette partie, j'ai voulu voir s'il était possible d'améliorer davantage le résultat avec des méthodes plus avancées. J'ai donc suivi la méthodologie proposé dans cet article : Multiscale Vessel Enhancement Filtering.

L'algorithme de FRANGI repose sur l'analyse des matrices hessiennes de l'image. En observant la forme de ce paraboloïde, on peut en déduire l'appartenance ou non d'un pixel à une structure tubulaire. En regardant le sens du paraboloïde, on en déduit si cette structure est un "trou" ou bien une "bosse".

1. Amélioration locale du contraste – CLAHE

C'est une égalisation d'histogramme local. L'image est divisée en carrés et chaque carré on égalise l'histogramme. Cela permet de renforcer les structures faibles sans amplifier le bruit.



2. Détection des structures tubulaires : vesselness

Pour détecter les structures tubulaires qui sont orientées selon toutes les directions et pas uniquement horizontalement ou verticalement, et peuvent être de différentes tailles.

Pour analyser le comportement local d'une image, on considère son développement de Taylor autour d'un point x_0 :

$$L(x_0 + \delta x, s) \approx L(x_0, s) + \delta x^\top \nabla_{x_0, s} L + \frac{1}{2} \delta x^\top H_{x_0, s} \delta x, \quad (1)$$

où $\nabla_{x_0, s}$ est le gradient et $H_{x_0, s}$ la matrice hessienne calculée en x_0 à l'échelle s .

L'information d'ordre deux est particulièrement pertinente pour la détection de vaisseaux. Le Hessien $H_{x_0, s}$ dans le cas 2D est une matrice symétrique 2×2 dont les valeurs propres λ_1, λ_2 (et vecteurs propres associés \hat{u}_1, \hat{u}_2) caractérisent la courbure locale :

$$H_{x_0, s} \hat{u}_k = \lambda_k \hat{u}_k, \quad k = 1, 2. \quad (2)$$

Notons,

$$R_B = \frac{|\lambda_1|}{|\lambda_2|}. \quad (3)$$

En 2D, cette mesure quantifie l'écart à une structure circulaire / "blob-like". Pour une ligne tubulaire idéale, R_B tend vers zéro.

Et,

$$S = \|H\|_F = \sqrt{\lambda_1^2 + \lambda_2^2}. \quad (4)$$

Fonction de vesselness en 2D

$$V(x, s) = \begin{cases} \lambda_2 > 0 & \text{si } \lambda_2 > 0 \\ \exp\left(-\frac{R_B^2}{2\beta^2}\right) \left(1 - \exp\left(-\frac{S^2}{2c^2}\right)\right) & \text{sinon} \end{cases}$$

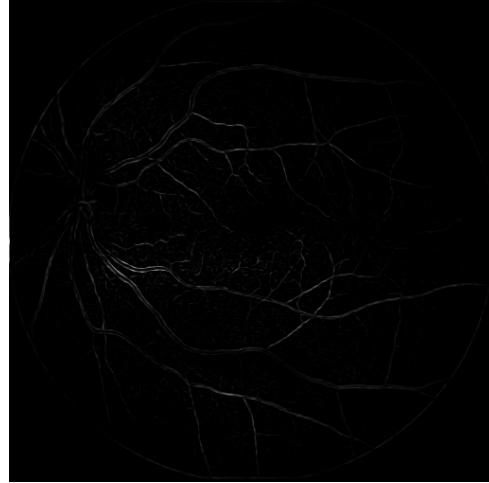
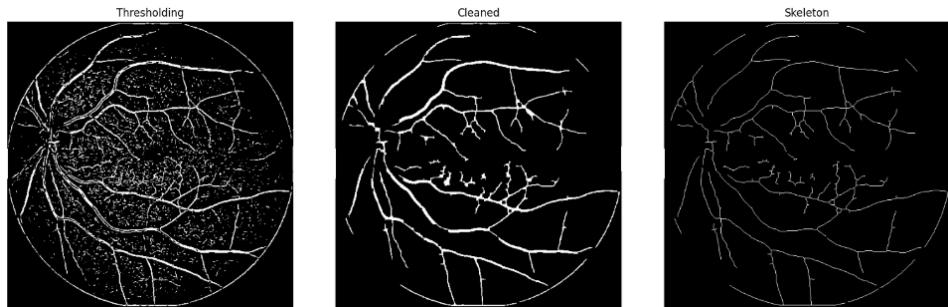


FIGURE 1 – Image après filtrage de Frangi

Nous remarquons que l'image est assez sombre, les vaisseaux sont peu marqué.

3. Seuillage adaptatif pour faire binariser l'image et faire ressortir les vaisseaux.

4. Débruitage et reconstruction pour retirer le bruit dans l'image et extraire seulement les vaisseaux. Comme précédemment, pour débruité l'image nous faisons une érosion. Puis une reconstruction par dilatation pour rétablit les formes intactes tout en supprimant le bruit.



4 Résultats

4.1 Evaluation

Précision

$$\text{Précision} = \frac{TP}{TP + FP}$$

La précision mesure la proportion de pixels détectés qui sont réellement corrects. Une faible quantité de faux positifs correspond donc à une bonne précision.

Recall

$$\text{Recall} = \frac{TP}{TP + FN}$$

Le rappel mesure la capacité à détecter l'ensemble des pixels présents dans l'image ground truth. Une faible quantité de faux négatifs correspond donc à un bon rappel.

Ainsi, la combinaison de ces deux métriques permet d'évaluer la qualité de la segmentation : elles indiquent si trop de zones ne contenant pas de vaisseaux sont détectées (FP), ou si trop de vaisseaux sont manqués (FN).

Squelettisation

Dans notre cas, la squelettisation est utile, car les vaisseaux sont fins et donc la représentation sous forme de squelette donne vision de la justesse de la segmentation. Comme notre objectif est principalement de détecter la présence des vaisseaux plutôt que leurs variations de largeur, la squelettisation ne pénalise pas les différences d'épaisseur.

Comment la squelettisation influence le calcul des TP, FP, FN ?

Grâce au squelette nous identifions :

- TP : pixels du squelette détectés qui correspondent réellement à l'axe d'un vaisseau dans la Ground Truth.
- FP : pixels du squelette détectés qui ne correspondent à aucun vaisseau dans la Ground Truth.
- FN : pixels du squelette de la Ground Truth qui ne sont pas détectés par la segmentation, c'est-à-dire les portions manquantes.

Méthode	Precision	Recall	Moyenne
Top hat → Otsu → Opening	0.72	0.59	0.67
Top hat → Otsu → Median	0.55	0.69	0.62
Top hat → Adaptive Threshold	0.80	0.45	0.63
Gradient	0.48	0.39	0.44
Frangi	0.77	0.68	0.73

TABLE 1 – Résultats des différentes pipeline étudiées

Nous obtenons les meilleurs résultats avec les filtres de Frangi. Notons tout de même que la première méthode : Top-hat → Otsu → Opening ; donne de très bons résultats. En approfondissant cette approche ou en ajoutant du post-traitement pour éliminer le bruit ou reconstruire les vaisseaux, nous pourrions améliorer encore la précision et le rappel.

Pour conclure, nous avons mis en œuvre plusieurs méthodologies pour extraire les vaisseaux dans une image de rétine. Dans un premier temps, nous avons utilisé des solutions "simples" comme la transformation top-hat combinée au seuillage d'Otsu, en y ajoutant quelques améliorations pour réduire le bruit. Ces méthodes sont rapides à implémenter et offrent des résultats globalement satisfaisants.

Dans un second temps, nous avons appliqué une méthode plus complexe basée sur la fonction de vesselness. En ajustant les paramètres β et c , il est possible de contrôler le nombre de faux positifs et de faux négatifs, selon ce que l'on souhaite privilégier. Ces paramètres permettent donc d'équilibrer précision et rappel.

Dans ce TP, j'ai cherché à **maximiser la moyenne de ces deux métriques** (recall + précision). Cependant, dans certains contextes, notamment pour le milieu médical, il peut être préférable de minimiser le nombre de faux négatifs ou de faux positifs, selon les exigences du diagnostic.